

COMPLÉMENTS PROBABILISTES

Ce chapitre est organisé autour de trois paragraphes :

- un morceau de cours sur la *variance*, que nous n'avons pas abordée au chapitre « Probabilités sur un univers fini »,
- un morceau de cours sur les *inégalités de concentration*, dont les plus simples sont au programme de MPSI,
- un complément sur la délicieuse et puissante *méthode probabiliste*.

1 VARIANCE, ÉCART-TYPE, COVARIANCE

Dans ce paragraphe, (Ω, P) est un espace probabilisé fini.

Définition (Moments, variance et écart-type d'une variable aléatoire réelle) Soit X une variable aléatoire réelle.

- **Moments** : Pour tout $k \in \mathbb{N}$, $E(X^k)$ est appelé le *moment d'ordre k de X* et $E((X - E(X))^k)$ son *moment centré d'ordre k* .
- **Variance** : On appelle *variance de X* le réel positif $V(X) = E((X - E(X))^2)$ et *écart-type de X* le réel $\sigma(X) = \sqrt{V(X)}$.
On dit que X est *réduite* si $V(X) = 1$.

L'espérance de X nous renseigne sur la position générale des valeurs de X dans $\mathbb{R}$ en nous indiquant leur moyenne pondérée, on dit que c'est un *indicateur de position*. D'autres questions se posent au-delà. Les valeurs de X sont-elles plutôt proches de leur espérance ou plutôt éloignées, dispersées ? Toute mesure de cette proximité à la moyenne est appelée un *indicateur de dispersion*. L'écart le plus naturel entre X et son espérance est bien sûr $|X - E(X)|$, donc l'écart moyen de X à sa moyenne vaut $E(|X - E(X)|)$, mais ce n'est pas l'indicateur de dispersion que les mathématiciens ont choisi de mettre en avant. Ils lui ont préféré la variance, c'est-à-dire l'écart quadratique moyen à la moyenne — quadratique parce qu'on passe au carré. Pourquoi ce choix moins naturel au premier abord ? Parce que la variance est plus facile à manipuler d'un point de vue calculatoire, comme on va le voir. Vive les identités remarquables !

Et l'écart-type, quelle différence avec la variance ? Si par exemple X représente une longueur, $V(X)$ représente une longueur au carré, donc il n'est pas possible de comparer directement la position moyenne $E(X)$ et sa dispersion moyenne $V(X)$ — un(e) physicien(ne) dirait que l'espérance et la variance ne sont pas homogènes. L'écart-type, au contraire, est homogène à une longueur, donc comparable à l'espérance.

Théorème (Propriétés de la variance) Soit X une variable aléatoire réelle.

- Expression développée** : $V(X) = E(X^2) - E(X)^2$. En particulier, si X est centrée, alors $V(X) = E(X^2)$.
- Effet d'une transformation affine** : Pour tous $a, b \in \mathbb{R}$: $V(aX + b) = a^2 V(X)$.
En particulier, si $\sigma(X) > 0$, la variable aléatoire $\frac{X - E(X)}{\sigma(X)}$ est centrée réduite.
- Nullité** : $V(X) = 0$ si et seulement si l'événement $\{X = E(X)\}$ est *presque certain*, i.e. de probabilité 1. On dit alors que X est *presque sûrement constante*.

Démonstration

$$(i) \quad V(X) = E\left(X^2 - 2 \overbrace{E(X)}^{\text{Constante}} X + \overbrace{E(X)^2}^{\text{Constante}}\right) = E(X^2) - 2E(X)E(X) + E(X)^2 = E(X^2) - E(X)^2.$$

$$(ii) \quad E(aX + b) = aE(X) + b, \quad \text{donc } V(aX + b) = E((aX + b - aE(X) - b)^2) = a^2 E((X - E(X))^2) = a^2 V(X).$$

$$\text{Enfin, si } \sigma(X) > 0, \text{ alors } E\left(\frac{X - E(X)}{\sigma(X)}\right) = \frac{E(X) - E(X)}{\sigma(X)} = 0 \text{ et } V\left(\frac{X - E(X)}{\sigma(X)}\right) = \frac{V(X)}{\sigma(X)^2} = 1.$$

$$(iii) \quad \text{D'après la formule de transfert : } V(X) = \sum_{x \in X(\Omega)} P(X = x) (x - E(X))^2 \quad \text{et les termes sommés sont tous positifs, donc :}$$

$$\begin{aligned} V(X) = 0 & \iff \forall x \in X(\Omega), \quad (P(X = x) = 0 \text{ ou } x = E(X)) & \iff \forall x \in X(\Omega) \setminus \{E(X)\}, \quad P(X = x) = 0 \\ & \iff P(X = E(X)) = 1 \quad \text{car } \sum_{x \in X(\Omega)} P(X = x) = 1. \end{aligned}$$

✗ **Attention !** Un événement A est dit *presque certain* si $P(A) = 1$. L'événement certain Ω est ainsi presque certain, mais la réciproque est fautive.

- Vous travaillerez en deuxième année avec des espaces probabilisés quelconques, éventuellement infinis. Intéressons-nous au tirage aléatoire sans préjugé d'un réel X dans l'intervalle $[0, 1]$. Intuitivement, et sous réserve qu'on puisse donner un sens à tout cela, la probabilité pour X d'appartenir à un intervalle $[a, b]$ inclus dans $[0, 1]$ vaut :

$$P(X \in A) = \frac{\lambda([a, b])}{\lambda([0, 1])} = b - a \quad \text{en notant } \lambda \text{ la longueur.}$$

En particulier, $P(X = x) = P(X \in [x, x]) = 0$ pour tout $x \in [0, 1]$, donc $P(X \neq 0) = 1$. L'événement $\{X \neq 0\}$ n'est pas certain car rien n'empêche X de valoir 0, mais il est presque certain. On dit aussi que $X \neq 0$ *presque sûrement*.

- Autre exemple plus artificiel. Soit $A \in \mathcal{P}(\Omega)$ un événement pour lequel $P(A) \in]0, 1[$. En particulier $A \neq \Omega$, autrement dit A n'est pas l'événement certain. Pourtant $P_A(A) = 1$, donc A est presque certain au sens de la probabilité P_A .

■ **Définition-théorème (Covariance de deux variables aléatoires réelles)** Soient X et Y deux variables aléatoires réelles. On appelle *covariance de X et Y* le réel $\text{cov}(X, Y) = E((X - E(X))(Y - E(Y)))$.

On dit que X et Y sont *décorrélées* si $\text{cov}(X, Y) = 0$.

Clairement : $V(X) = \text{cov}(X, X)$ et $\text{cov}(Y, X) = \text{cov}(X, Y)$.

(i) **Expression développée :** $\text{cov}(X, Y) = E(XY) - E(X)E(Y)$.

En particulier, si X et Y sont indépendantes, X et Y sont décorrélées.

(ii) **Variance d'une somme :** $V(X + Y) = V(X) + 2\text{cov}(X, Y) + V(Y)$.

Plus généralement, pour des variables aléatoires $X_1, \dots, X_n$ sur Ω : $V\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n V(X_i) + 2 \sum_{1 \leq i < j \leq n} \text{cov}(X_i, X_j)$.

D'après (i) et (ii), si X et Y sont indépendantes (ou seulement décorrélées) : $V(X + Y) = V(X) + V(Y)$. De même,

si $X_1, \dots, X_n$ sont indépendantes (ou seulement deux à deux décorrélées) : $V\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n V(X_i)$.

(iii) **Inégalité de Cauchy-Schwarz version covariance :** $|\text{cov}(X, Y)| \leq \sigma(X)\sigma(Y)$.

✗ **Attention !** Deux variables décorrélées ne sont pas indépendantes en général. Par exemple, pour toute variable aléatoire X uniforme sur $\{-1, 0, 1\}$: $\text{cov}(X, X^2) = E(X^3) - E(X)E(X^2) = 0 - 0 \cdot E(X^2) = 0$, mais X et X^2 ne sont pas indépendantes car $P(X = 0, X^2 = 1) = 0$ alors que $P(X = 0)P(X^2 = 1) = \frac{1}{3} \times \frac{2}{3} \neq 0$.

Démonstration

$$(i) \quad \text{cov}(X, Y) = E\left(XY - \overbrace{X E(Y)}^{\text{Constante}} - \overbrace{E(X) Y}^{\text{Constante}} + \overbrace{E(X) E(Y)}^{\text{Constante}}\right) = E(XY) - E(X)E(Y) - E(X)E(Y) + E(X)E(Y) = E(XY) - E(X)E(Y).$$

$$(ii) \quad V(X + Y) = E\left((X - E(X) + Y - E(Y))^2\right) = E\left((X - E(X))^2 + 2(X - E(X))(Y - E(Y)) + (Y - E(Y))^2\right) = V(X) + 2\text{cov}(X, Y) + V(Y).$$

(iii) D'après l'inégalité de Cauchy-Schwarz plus générale sur les variables aléatoires :

$$|\text{cov}(X, Y)| = |E((X - E(X))(Y - E(Y)))| \leq \sqrt{E((X - E(X))^2)} \sqrt{E((Y - E(Y))^2)} = \sigma(X)\sigma(Y). \quad \blacksquare$$

Nous disposons ainsi de deux inégalités de Cauchy-Schwarz en probabilités :

$$|E(XY)| \leq \sqrt{E(X^2)} \sqrt{E(Y^2)} \quad \text{et} \quad |\text{cov}(X, Y)| \leq \sigma(X)\sigma(Y),$$

mais la deuxième inégalité est une simple conséquence de la première.

Exemple Pour toute variable aléatoire centrée X : $E(|X|) \leq \sqrt{V(X)}$ car d'une part $V(X) = E(X^2)$, et d'autre part, d'après l'inégalité de Cauchy-Schwarz : $E(|X|) = E(1 \cdot |X|) \leq \sqrt{E(1)} \sqrt{E(X^2)}$.

■ **Théorème (Variance de la loi de Bernoulli et de la loi binomiale)** Soient X une variable aléatoire et $p \in [0, 1]$.

(i) Si $X \sim \mathcal{B}(p)$, alors $V(X) = p(1 - p)$.


(ii) Si $X \sim \mathcal{B}(n, p)$, alors $V(X) = np(1 - p)$.

Démonstration

- (i) $E(X^2) = P(X = 1) \cdot 1^2 + P(X = 0) \cdot 0^2 = p$, donc $V(X) = E(X^2) - E(X)^2 = p - p^2 = p(1 - p)$.
- (ii) Soient $X_1, \dots, X_n$ des variables aléatoires indépendantes sur Ω de même loi de Bernoulli $\mathcal{B}(p)$. Comme $X_1 + \dots + X_n \sim \mathcal{B}(n, p)$, alors $V(X_1 + \dots + X_n) \stackrel{\text{Indép.}}{=} V(X_1) + \dots + V(X_n) = np(1 - p)$. Ce calcul ne concerne a priori pas la variable aléatoire X de l'énoncé, dont on ne sait pas si elle peut être décomposée ou non comme une somme de n variables aléatoires indépendantes de loi $\mathcal{B}(p)$, mais l'espérance d'une variable aléatoire ne dépend que de sa loi, donc le calcul que nous venons de faire dans le cas particulier de la somme $X_1 + \dots + X_n$ est en fait emblématique de toute situation binomiale. ■

L'exemple qui suit relève bien plus du chapitre « Espaces préhilbertiens réels » que du chapitre en cours, mais il fait appel indirectement aux notions de variance et covariance et je préfère vous le présenter ici.

Exemple Il est courant qu'on ait à expliquer une quantité y par une quantité x , en physique ou en économie par exemple. Faisons l'hypothèse que y est une fonction affine de x , disons $y = mx + p$ pour certains $m, p \in \mathbb{R}$. Comment déterminer m et p quand on a effectué n mesures expérimentales $(x_1, y_1), \dots, (x_n, y_n)$ du couple (x, y) ? Le nuage des mesures $(x_1, y_1), \dots, (x_n, y_n)$ est en principe assez proche de la droite idéale visée, mais il n'est pas inclus dedans a priori, ne serait-ce qu'en raison des erreurs de mesure. Nous cherchons donc deux réels m et p pour lesquels la droite d'équation $y = mx + p$ est « la plus proche possible » du nuage de points. Ce problème est appelé un problème de *régression linéaire* — *linéaire* en raison de la relation $y = mx + p$ qui lie x et y .



Mais la droite « la plus proche » en quel sens ? Pour tout $i \in \llbracket 1, n \rrbracket$, notre mesure de y pour $x = x_i$ a fourni la valeur y_i , mais en l'absence d'erreurs de mesure, nous aurions trouvé $mx_i + p$. L'erreur de la $i^{\text{ème}}$ mesure vaut donc $|y_i - mx_i - p|$, mais ce n'est pas cet écart ponctuel qui nous intéresse. Nous nous intéressons plutôt à un écart global entre le nuage de points et la droite d'équation $y = mx + p$. Plusieurs définitions de cet écart sont possibles, par exemple :

$$\max_{1 \leq i \leq n} |y_i - mx_i - p|, \quad \sum_{i=1}^n |y_i - mx_i - p| \quad \text{ou} \quad \sqrt{\sum_{i=1}^n (y_i - mx_i - p)^2}.$$

Nous travaillerons ici dans le cadre de cette troisième possibilité. La méthode de régression linéaire correspondante est appelée la *méthode des moindres carrés*.

Nous cherchons finalement deux réels m et p pour lesquels la quantité $\sqrt{\sum_{i=1}^n (y_i - mx_i - p)^2}$ est minimale — s'ils existent.

Dans l'espace euclidien canonique $\mathbb{R}^n$, posons : $x = (x_1, \dots, x_n)$, $y = (y_1, \dots, y_n)$, $u = \left(\frac{1}{n}, \dots, \frac{1}{n}\right)$ et $F = \text{Vect}(x, u)$.

Aussitôt : $\inf_{m, p \in \mathbb{R}} \sqrt{\sum_{i=1}^n (y_i - mx_i - p)^2} = \inf_{m, p \in \mathbb{R}} \|y - mx - npu\| = \inf_{f \in F} \|y - f\| = d(y, F)$. Or d'après le théorème précédent, en notant p la projection orthogonale de $\mathbb{R}^n$ sur F , la distance $d(y, F)$ est atteinte en un et un seul point, à savoir $p(y) = mx + npu$ où m et p sont les deux réels que nous cherchons. Calculons donc $p(y)$. Or $y - p(y) \in F^\perp$, donc $\langle x, y - p(y) \rangle = 0$ et $\langle u, y - p(y) \rangle = 0$, i.e. : $m\|x\|^2 + np\langle x, u \rangle = \langle x, y \rangle$ et $m\langle x, u \rangle + p = \langle y, u \rangle$ — deux équations, deux inconnues. Après calcul : $m = \frac{\langle x, y \rangle - n\langle x, u \rangle \langle y, u \rangle}{\|x\|^2 - n\langle x, u \rangle^2}$ et $p = \langle y, u \rangle - m\langle x, u \rangle$. Posons alors :


$$\begin{aligned} E(x) &= \langle x, u \rangle = \frac{1}{n} \sum_{i=1}^n x_i \quad (\text{moyenne empirique des } x_i), & E(y) &= \langle y, u \rangle = \frac{1}{n} \sum_{i=1}^n y_i \quad (\text{moyenne empirique des } y_i), \\ V(x) &= \frac{1}{n} \|x - nE(x)u\|^2 = \frac{1}{n} \sum_{i=1}^n (x_i - E(x))^2 \quad (\text{variance empirique des } x_i) \\ \text{et} \quad \text{cov}(x, y) &= \frac{1}{n} \langle x - nE(x)u, y - nE(y)u \rangle = \frac{1}{n} \sum_{i=1}^n (x_i - E(x))(y_i - E(y)) \quad (\text{covariance empirique des } x_i \text{ et des } y_i). \end{aligned}$$

Il n'est pas dur de vérifier que : $nV(x) = \|x\|^2 - n\langle x, u \rangle^2$ et $n \text{cov}(x, y) = \langle x, y \rangle - n\langle x, u \rangle \langle y, u \rangle$. Conclusion :

$$m = \frac{\text{cov}(x, y)}{V(x)} \quad \text{et} \quad p = E(y) - mE(x).$$

Le problème de ce qui précède, c'est que toute variable expliquée y ne dépend pas de manière affine de sa variable explicative x . La méthode des moindres carrés est-elle caduque au-delà ? Parfois oui.

Sur la figure ci-contre, on peut émettre l'hypothèse d'une relation de la forme $y = \lambda x^\alpha$ entre x et y où λ et α sont deux réels à déterminer. On se ramène au cas affine en réécrivant les choses ainsi : $\ln y = \alpha \ln x + \ln \lambda$. Dans ce cas simple, ce sont les réels α et $\ln \lambda$ qu'on estimera par régression linéaire simple.



2 INÉGALITÉS DE CONCENTRATION

De nouveau, (Ω, P) est un espace probabilisé fini. Deux questions sur la distribution des valeurs d'une variable aléatoire nous occuperont dans ce paragraphe.

- Avec quelle probabilité les valeurs d'une variable aléatoire réelle X peuvent-elles être grandes en valeur absolue, i.e. loin de 0 ? En d'autres termes, comment majorer $P(|X| \geq a)$ pour tout $a > 0$?
- Avec quelle probabilité les valeurs d'une variable aléatoire réelle X peuvent-elles être loin de son espérance ? En d'autres termes, comment majorer $P(|X - E(X)| \geq a)$ pour tout $a > 0$?

Toute majoration de ce genre est appelée une *inégalité de concentration*. L'*inégalité de Markov* est la première du genre et leur mère à toutes.

Théorème (Inégalité de Markov) Soit X une variable aléatoire réelle. Pour tout $a > 0$: $P(|X| \geq a) \leq \frac{E(|X|)}{a}$.

Comme $\{|X| > a\} \subset \{|X| \geq a\}$, on peut remplacer $P(|X| \geq a)$ par $P(|X| > a)$ si on veut.

Démonstration Tout repose sur les inégalités suivantes : $a \mathbb{1}_{\{|X| \geq a\}} \leq |X| \mathbb{1}_{\{|X| \geq a\}} \leq |X|$. Par croissance de l'espérance : $a P(|X| \geq a) = E(a \mathbb{1}_{\{|X| \geq a\}}) \leq E(|X| \mathbb{1}_{\{|X| \geq a\}}) \leq E(|X|)$.

À mon avis, c'est ainsi qu'il faut écrire cette preuve, dont on voit bien qu'elle repose sur la croissance de l'espérance, mais on peut aussi l'écrire avec des sommes si on craint les indicatrices :

$$a P(|X| \geq a) = a \sum_{\substack{x \in X(\Omega) \\ |x| \geq a}} P(X = x) \leq \sum_{\substack{x \in X(\Omega) \\ |x| \geq a}} P(X = x) |x| \leq \sum_{x \in X(\Omega)} P(X = x) |x| = E(|X|).$$

L'inégalité de Markov n'est pas souvent utilisée sous sa forme officielle. Au lieu de l'appliquer directement à X , on l'applique généralement à $f(X)$ pour une fonction bien choisie.

Exemple Soient X une variable aléatoire et $f : \mathbb{R} \rightarrow \mathbb{R}_+^*$ une fonction croissante. Pour tout $a \in \mathbb{R}$:

$$P(X \geq a) \leq \frac{E(f(X))}{f(a)}.$$

Démonstration Par croissance de f : $\{X \geq a\} \subset \{f(X) \geq f(a)\}$, donc d'après l'inégalité de Markov et par positivité stricte de f : $P(X \geq a) \leq P(f(X) \geq f(a)) \leq \frac{E(f(X))}{f(a)}$.

Exemple Soit X une variable aléatoire de loi binomiale $\mathcal{B}\left(4n, \frac{1}{2}\right)$. Comment majorer efficacement $P(X \leq n)$? Déjà, X et $4n - X$ ont même loi, donc $P(X \leq n) = P(X \geq 3n)$.

- **Application brutale de l'inégalité de Markov** : X est positive, donc $P(X \leq n) = P(X \geq 3n) \leq \frac{E(X)}{3n} = \frac{2}{3n}$.
- **Application raffinée de l'inégalité de Markov** : Pour tout $t > 0$: $E(e^{tX}) = \frac{1}{2^{4n}} \sum_{k=0}^{4n} \binom{4n}{k} e^{kt} = \left(\frac{e^t + 1}{2}\right)^{4n}$
d'après la formule de transfert, donc $P(X \leq n) = P(X \geq 3n) \stackrel{t \geq 0}{\leq} P(e^{tX} \geq e^{3nt}) \leq \frac{E(e^{tX})}{e^{3nt}} = \left(\frac{(e^t + 1)^4}{16e^{3t}}\right)^n$. Or une étude rapide de la fonction $x \mapsto \frac{(x+1)^4}{x^3}$ sur $\mathbb{R}_+^*$ montre qu'elle est minimale en 3. Pour $t = \ln 3$: $P(X \leq n) \leq \left(\frac{16}{27}\right)^n$.

L'inégalité de Bienaymé-Tchebychev mesure à présent l'écart à la moyenne des valeurs d'une variable aléatoire réelle.

Théorème (Inégalité de Bienaymé-Tchebychev) Soit X une variable aléatoire réelle. Pour tout $a > 0$:

$$P(|X - E(X)| \geq a) \leq \frac{V(X)}{a^2}.$$

Démonstration Par croissance de la fonction $x \mapsto x^2$ sur $\mathbb{R}_+$: $\{|X - E(X)| \geq a\} \subset \{(X - E(X))^2 \geq a^2\}$. En réalité, par croissance stricte, cette inclusion est même une égalité, mais on s'en fiche ici. D'après l'inégalité

$$\text{de Markov, il en découle que : } P(|X - E(X)| \geq a) \leq P((X - E(X))^2 \geq a^2) \leq \frac{E((X - E(X))^2)}{a^2} = \frac{V(X)}{a^2}.$$

Théorème (Loi faible des grands nombres) Soient $X_1, \dots, X_n$ des variables aléatoires réelles indépendantes de même loi. On note m leur espérance commune et σ leur écart-type et on pose $S_n = X_1 + \dots + X_n$. Pour tout $\varepsilon > 0$:

$$P\left(\left|\frac{S_n}{n} - m\right| \geq \varepsilon\right) \leq \frac{\sigma^2}{n\varepsilon^2}.$$

En particulier : $P\left(\left|\frac{S_n}{n} - m\right| \geq \varepsilon\right) \xrightarrow{n \rightarrow +\infty} 0.$

Démonstration Il suffit d'appliquer l'inégalité de Bienaymé-Tchebychev à $\frac{S_n}{n}$. En effet :

$$E\left(\frac{S_n}{n}\right) = \frac{E(X_1) + \dots + E(X_n)}{n} = \frac{nm}{n} = m \quad \text{et} \quad V\left(\frac{S_n}{n}\right) = \frac{V(S_n)}{n^2} \stackrel{\text{Indép.}}{=} \frac{V(X_1) + \dots + V(X_n)}{n^2} = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}.$$

Comme voulu : $P\left(\left|\frac{S_n}{n} - m\right| \geq \varepsilon\right) = P\left(\left|\frac{S_n}{n} - E\left(\frac{S_n}{n}\right)\right| \geq \varepsilon\right) \leq \frac{1}{\varepsilon^2} V\left(\frac{S_n}{n}\right) = \frac{\sigma^2}{n\varepsilon^2}.$

Mais que raconte la loi faible ? On s'intéresse à une grandeur d'espérance m et d'écart-type σ . On la mesure dans un premier temps à l'occasion d'une unique expérience de résultat noté X_1 . D'après l'inégalité de Bienaymé-Tchebychev, pour tout $\varepsilon > 0$: $P(|X_1 - m| \geq \varepsilon) \leq \frac{\sigma^2}{\varepsilon^2}$. La mesure X_1 est donc à distance supérieure à ε de m avec probabilité au plus $\frac{\sigma^2}{\varepsilon^2}$.

Si on souhaite estimer m avec une certaine précision, l'expérience nous enseigne qu'une seule mesure a peu de chances de suffire. On obtient de meilleures estimations de m en augmentant le nombre de mesures. La théorie des probabilités confirme-t-elle cette intuition ? Oui, et c'est au fond cela la loi faible des grands nombres. On effectue à présent n mesures $X_1, \dots, X_n$ — indépendantes — de la grandeur étudiée. Avec les notations du théorème : $E\left(\frac{S_n}{n}\right) = m$ et $V\left(\frac{S_n}{n}\right) = \frac{\sigma^2}{n}$, donc $\sigma\left(\frac{S_n}{n}\right) = \frac{\sigma}{\sqrt{n}}$. En résumé :

La moyenne de n variables aléatoires indépendantes de même loi, d'espérance m et d'écart-type σ , admet toujours m pour espérance, mais $\frac{\sigma}{\sqrt{n}}$ pour écart-type.

En d'autres termes, on gagne un facteur $\frac{1}{\sqrt{n}}$ en écart-type en effectuant n mesures plutôt qu'une seule. Chaque nouvelle mesure rapproche de la certitude que la moyenne empirique $\frac{S_n}{n}$ est proche de son espérance m .

Les lois des grands nombres sont philosophiquement importantes car elles justifient l'interprétation *fréquentiste* que nous avons des probabilités. Qu'avons-nous en tête quand nous affirmons que la probabilité d'apparition de chaque face d'un dé équilibré à 6 faces vaut $\frac{1}{6}$? Nous signifions par là une vérité sur le monde qui n'a rien à voir avec le fait que de tels dés existent et qu'on peut les lancer un nombre indéfini de fois. Cette probabilité vaudrait $\frac{1}{6}$ même si l'humanité s'était de tout temps interdit de lancer un dé. Cela dit, le fait est que nous avons une autre notion de probabilité en tête simultanément, nous avons aussi l'habitude de constater que lorsqu'on lance un dé de nombreuses fois, la fréquence d'apparition de chaque face tend vers $\frac{1}{6}$ à mesure que ce nombre augmente. Les lois des grands nombres réconcilient les deux points de vue. Quand on répète indéfiniment une expérience aléatoire, la fréquence d'un événement tend vers la probabilité a priori de cet événement, i.e. vers sa probabilité indépendamment de toute expérience.

3 LA MÉTHODE PROBABILISTE

Popularisée par le mathématicien hongrois Paul Erdős (1913-1996), la *méthode probabiliste* est un mode de raisonnement pour prouver l'existence de certains objets. L'idée est simple. Soient E un ensemble — fini car nous sommes en MPSI — et A une partie de E définie explicitement par telle ou telle propriété. On souhaite montrer que A est non vide. Pour cela, on se donne une variable aléatoire X à valeurs dans E définie sur un espace probabilisé (Ω, P) caché et on tente de montrer que $P(X \in A) > 0$. Si on y arrive, l'événement $\{X \in A\}$ est non vide, donc A aussi a fortiori.

Le plus souvent, cela dit, la méthode probabiliste conclut un calcul d'espérance plutôt qu'un calcul pur de probabilité. D'après le petit résultat qui suit, on peut en effet savoir qu'un objet existe en calculant une espérance.

Théorème (L'espoir fait vivre) Pour toute variable aléatoire réelle X : $P(X \leq E(X)) > 0$ et $P(X \geq E(X)) > 0$. En particulier, les ensembles $\{x \in X(\Omega) \mid x \leq E(X)\}$ et $\{x \in X(\Omega) \mid x \geq E(X)\}$ sont non vides.

Démonstration Posons $m = E(X)$. Quitte à remplacer X par $-X$, il suffit de montrer que $P(X \leq m) > 0$. Par l'absurde, si $P(X \leq m) = 0$, alors $P(X = x) = 0$ pour tout $x \in X(\Omega) \cap]-\infty, m]$, donc :

$$0 = E(X - m) = \sum_{x \in X(\Omega)} P(X = x)(x - m) = \sum_{\substack{x \in X(\Omega) \\ x > m}} P(X = x) \underbrace{(x - m)}_{> 0},$$

donc $P(X = x) = 0$ pour tout $x \in X(\Omega) \cap]m, +\infty[$. Par conséquent, $P(X = x) = 0$ pour tout $x \in X(\Omega)$ — contradiction car $\sum_{x \in X(\Omega)} P(X = x) = 1$. ■

Reprenons maintenant les notations de l'introduction. Il arrive que la partie A dont on veut montrer qu'elle est non vide soit définie par une fonction $f : E \rightarrow \mathbb{R}$ par une condition du genre $A = \{x \in E \mid f(x) \leq m\}$ pour un certain $m \in \mathbb{R}$. L'ensemble $\{x \in X(\Omega) \mid f(x) \leq E(f(X))\}$ est non vide d'après le théorème précédent, donc A l'est aussi si on arrive à montrer que $E(f(X)) \leq m$.

Exemple Soit E un espace euclidien. Pour tous vecteurs unitaires $u_1, \dots, u_n \in E$, il existe des signes $\varepsilon_1, \dots, \varepsilon_n \in \{-1, 1\}$ pour lesquels $\|\varepsilon_1 u_1 + \dots + \varepsilon_n u_n\| \leq \sqrt{n}$.





En d'autres termes, si on se déplace de $\pm u_1$, puis $\pm u_2$... dans E avec 0_E comme point de départ, il est toujours possible de rester assez proche de 0_E , assez proche au sens où $\sqrt{n} = o(n)$. On ne peut pas espérer mieux que $\sqrt{n}$ en toute généralité car si $u_1, \dots, u_n$ sont orthogonaux, alors pour tous $\varepsilon_1, \dots, \varepsilon_n \in \{-1, 1\}$: $\|\varepsilon_1 u_1 + \dots + \varepsilon_n u_n\|^2 = \|\varepsilon_1 u_1\|^2 + \dots + \|\varepsilon_n u_n\|^2 = n$ d'après le théorème de Pythagore, donc $\|\varepsilon_1 u_1 + \dots + \varepsilon_n u_n\| = \sqrt{n}$.

Démonstration Soient $R_1, \dots, R_n$ des variables aléatoires de Rademacher indépendantes. D'après le petit résultat précédent, il nous suffit de montrer que $E(\|R_1 u_1 + \dots + R_n u_n\|^2) \leq n$. Or justement :

$$\begin{aligned} E(\|R_1 u_1 + \dots + R_n u_n\|^2) &= E(\langle R_1 u_1 + \dots + R_n u_n, R_1 u_1 + \dots + R_n u_n \rangle) = E\left(\|u_1\|^2 + \dots + \|u_n\|^2 + 2 \sum_{1 \leq i < j \leq n} R_i R_j \langle u_i, u_j \rangle\right) \\ &= n + 2 \sum_{1 \leq i < j \leq n} E(R_i R_j) \langle u_i, u_j \rangle \stackrel{\text{Indép.}}{=} n + 2 \sum_{i < j} \underbrace{E(R_i)}_{=0} \underbrace{E(R_j)}_{=0} \langle u_i, u_j \rangle = n. \end{aligned}$$

Et c'est tout ! Cela dit, puisque $E(\|R_1 u_1 + \dots + R_n u_n\|^2) \geq n$, il existe aussi des signes $\varepsilon'_1, \dots, \varepsilon'_n \in \{-1, 1\}$ pour lesquels $\|\varepsilon'_1 u_1 + \dots + \varepsilon'_n u_n\| \geq \sqrt{n}$.

Et maintenant, un peu de théorie des graphes. On appelle *graphe* tout couple $G = (S, A)$ dans lequel S est un ensemble et A est une partie de l'ensemble $\mathcal{P}_2(S)$ des paires d'éléments de S . Les éléments de S sont appelés les *sommets* de G et les éléments de A ses *arêtes*. Deux sommets x et y de G sont dits *adjacents* si $\{x, y\} \in A$. On dit aussi, le cas échéant, que y est un *voisin* de x .



Exemple Soit $G = (S, A)$ un graphe pour lequel $|S| = 2n$ avec $n \geq 1$ et $|A| \geq 1$. On peut partitionner S à l'aide de deux parties S_1 et S_2 de cardinal n de telle sorte que strictement plus de $\frac{|A|}{2}$ arêtes relient un sommet de S_1 à un sommet de S_2 .

Démonstration Soit S_1 une n -combinaison aléatoire de S . Ainsi, $S_1 \sim \mathcal{U}(\mathcal{P}_n(S))$. Notons N le nombre d'arêtes de G qui relient un sommet de S_1 à un sommet de $S_2 = S \setminus S_1$. Pour montrer le résultat, il nous suffit de montrer que $E(N) > \frac{|A|}{2}$.

Pour toute arête $a \in A$, notons E_a l'événement « L'un des sommets de a appartient à S_1 et l'autre à S_2 ». Ainsi $N = \sum_{a \in A} \mathbb{1}_{E_a}$, donc $E(N) = \sum_{a \in A} P(E_a)$. Pour montrer que $E(N) > \frac{|A|}{2}$, il nous suffit donc de montrer que $P(E_a) > \frac{1}{2}$ pour toute arête $a \in A$ car $|A| \geq 1$. Fixons $a \in A$ et notons x et y ses deux sommets. Comme $S_1 \sim \mathcal{U}(\mathcal{P}_n(S))$:

$$P(E_a) = \frac{\left| \left\{ T \in \mathcal{P}_n(S) \mid (x, y) \in T \times (S \setminus T) \text{ ou } (x, y) \in (S \setminus T) \times S \right\} \right|}{|\mathcal{P}_n(S)|}.$$

Or se donner une partie $T \in \mathcal{P}_n(S)$ pour laquelle $(x, y) \in T \times (S \setminus T)$ revient à se donner une $(n-1)$ -combinaison quelconque de $S \setminus \{x, y\}$ ($\binom{2n-2}{n-1}$ possibilités). Idem dans le cas disjoint $(x, y) \in (S \setminus T) \times T$. Conclusion :

$$P(E_a) = \frac{2 \times \binom{2n-2}{n-1}}{\binom{2n}{n}} = \frac{n}{2n-1} > \frac{1}{2}.$$